

文档解析服务的版面恢复评估报告

评估对象：parser-gateway 2.4.0 日期：2026 年 7 月 28 日

摘要

本报告总结 parser-gateway 在采购合同、巡检记录和知识库导出件上的版面恢复实验。数据来自 1,200 份脱敏业务文档，覆盖 6 种办公软件导出格式。系统在单栏正文和规则表格上稳定，但跨页表格、脚注与图片说明混排时仍会结构漂移。已有研究指出，阅读顺序恢复必须结合版面区域与语义线索 [2]；本次结果也支持这一判断。

背景

知识库团队计划将历史文档迁移到统一检索索引。仅提取纯文本会丢失标题层级、表头绑定和引用关系，导致问答系统把“适用范围”误认为“结论”。样本含合同 480 份、设备台账 360 份、技术说明书 360 份；扫描件占比分别为 18%、42%、9%。

文档族	样本数	平均页数	扫描占比
采购合同	480	7.2	18%
设备台账	360	3.8	42%
技术说明书	360	11.6	9%

Table 1: 评估样本构成

Observations

区域检测

区域检测器宏平均 F1 为 0.93。页眉中出现项目编号时，约 4.1% 的样本被误判为正文首句；Zhang et al., 2024 的企业文档实验也记录了这一现象，但正文没有版本后缀，无法判断其指向预印本还是期刊扩展版。

阅读顺序

双栏技术说明书的阅读顺序准确率为 0.88。带侧栏提示的页面最容易跳读。Li, 2024 提出的图模型可能缓解此问题，但本实验未复现其全部特征工程，只能作为方向性参考。

表格与脚注

表格字段 F1 为 0.86。跨页续表的第二页常缺少列名，系统会把“单位：件”绑定到上一行。赵敏等人的研究将其归因于表头传播策略 [4]，另一篇同年论文则归因于脚注锚点损失 [5]；作者、年份高度相似，当前界面未提供消歧提示。

重要结论

1. 版面区域与语义分类需要联合建模：只依赖字体大小会把加粗条款误标为标题。
2. 续页应显式继承表头并保留“续表”标记。
3. 引用解析必须保存原始字符串、候选集合和页码证据，目标不唯一时不能强行绑定。

错误样例与复核记录

编号	原文片段	系统输出	复核意见
R-01	“表 3（续）” 位于页首，列名缺失	新建表 3，首行作为表头	应继承上一页列名
R-02	“见 Zhang et al., 2024”	绑定 Zhang 2024a	正文没有 a/b 后缀，存在两条候选
R-03	页脚“资料来源：项目组整理”	识别为参考文献	属于来源说明
R-04	右栏脚注编号 7	绑定左栏正文	先恢复栏内阅读顺序
R-05	图注跨页	图注截断	保留图注并建立图-注关系

Implementation notes

线上配置将标题候选阈值设为 0.72、表格候选阈值设为 0.68。建议扫描件启用倾斜校正和行基线聚类；引用则增加候选集合字段并把 unresolved 状态传给质量层。王、陈的版面恢复研究也建议在低置信度时保留多候选 [1]，但未覆盖跨语言文献。

待办事项

优先级	工作项	负责人	截止日期
P0	保存引用原文和候选集合	解析服务	2026-08-21
P1	增加续表表头继承规则	版面算法	2026-08-28
P1	双栏脚注加入栏级排序特征	OCR 平台	2026-09-04
P2	标注界面增加作者年消歧提示	数据工具	2026-09-11

附录：评估口径

页面级阅读顺序准确率要求文本块相对顺序与金标准一致；字段级 **F1** 以单元格边界和文本归属同时正确为准。引用只有在作者、年份、标题和页码证据足够时才计为 **verified**，否则进入 **manual review**。

1. 标题是否由编号、字体、前后空白和语义共同支持？
2. 表格是否跨页，下一页是否有“续表”或重复列名？
3. 引用字符串是否含页码、版本或 **a/b** 后缀？
4. 多候选均合理时是否保留 **unresolved**？

References

1. 王伟, 陈晨. 面向复杂版面的文档结构恢复 [J]. 中文信息学报, 2023, 37(6):45–58. DOI:10.1000/cip.2023.3706.
2. Zhang, Y., Liu, H. Layout-aware reading order recovery for enterprise documents[J]. Information Processing Letters, 2024, 189:106–118. DOI:10.1000/ipl.2024.189106.
3. Zhang, Y., Liu, H. Layout-aware reading order recovery for enterprise documents: extended evaluation[R]. arXiv:2407.01921, 2024. (与文献 [2] 作者年相同, 正文未区分 a/b)
4. 赵敏, 周海. 表格字段绑定的来源约束与安全降级 [J]. 软件学报, 2025, 36(8):1771–1787. DOI:10.1000/js.2025.3608.
5. 赵敏, 周海. 脚注锚点驱动的跨页表格解析 [J]. 软件学报, 2024, 35(12):2890–2904. DOI:10.1000/js.2024.3512.
6. Li, Q. Graph-based document layout parsing with side-note constraints[C]//Proceedings of DocEng. 2024:88–97. DOI:10.1000/doceng.2024.88.