

面向企业知识库的证据保留式文档解析研究

Evidence-preserving Document Parsing for Enterprise Knowledge Bases

作者	陈琳, 周海, 王倩	文档类型	技术研究报告
版本	1.2	发布日期	2026-08-17
数据集	Shared Dev v1	状态	Reviewed

摘要

企业知识库中的 PDF、扫描件和 Office 文档同时包含正文、表格、图注和引用。只抽取纯文本会损失阅读顺序和来源证据。本文提出一套保留页面、边界框、表格网格和引用关系的解析流程，并在合成但业务真实的文档集上进行评估。结果表明，结构证据能够减少表格字段错绑和引用目标误判。

关键词：文档解析；证据保留；表格绑定；标题树；引用关系；质量门

1 引言

1.1 背景

企业文档通常由多个团队维护，标题、版本和附件并不统一。检索系统如果只保存 Markdown，会难以回答“这个数字来自哪一页”或“该结论引用了哪篇文献”。已有研究指出，布局与语义结构对文档问答同样重要 [1-2]。

1.2 问题定义

给定一个包含文本块、表格、图片和引用的文档，系统需要输出统一的 ParsedDocument，并保留可回溯的 source locator。质量层还要区分 verified、inferred 和 manual review required，而不是把所有推断都当成事实 [3]。

1.3 贡献

1. 定义包含页码、bbox、表格 cell/span 和原生产物引用的证据模型；
2. 提出针对多级表头和跨页表格的安全绑定规则；
3. 建立标题树和正文引用到参考文献的可验证关系；
4. 使用固定样例和质量门报告评估安全降级行为。

2 方法

2.1 输入预检

预检器记录文件类型、页数、文本层、扫描页比例和语言提示。路由器根据能力声明选择解析器，解析器实际执行来源写入 provenance [4]。

2.2 统一结构

每个文本块有稳定 block id、阅读顺序和 source anchor。表格 cell 保留 start row、start col、row span、col span；合并表头生成完整 column path，例如“训练集 / 准确率”。

2.3 质量门

质量门按照以下规则决定状态：证据充分且关系唯一时为 verified；只有顺序和语义支持时为 inferred；目标不唯一时进入 manual review；关键事实缺失且其他模型可补足时进入 reparsed required [5]。

3 实验设置

3.1 样例与指标

能力	正例数	反例数	主要指标
普通正文与阅读顺序	2	1	文本完整度、block 顺序
多级表头与字段绑定	2	2	column path、row key、来源
标题层级恢复	2	1	parent_child 唯一性
编号引用绑定	2	2	reference_of 目标唯一性
OCR 图片质量	2	2	token 可读性、低质量拦截

3.2 评估流程

每个样例都使用相同的输入摘要和 manifest commit。运行记录包含路由决定、实际解析器、耗时、ParsedDocument schema、质量状态、问题数量和产物位置。失败和不可用结果不会从批量报告中删除。

3.3 表格结果

样例	网格恢复	表头路径	字段绑定	最终状态
采购比价正例	pass	完整	verified	pass
跨页续表正例	pass	完整	verified	pass with warnings
列漂移反例	partial	不确定	unavailable	manual review
无稳定行键	partial	表级	unavailable	manual review

4 讨论

4.1 安全降级

在表格结构不唯一时，减少绑定数量比输出错误关系更安全。质量报告必须同时记录缺失证据、受影响 block 和重新解析建议 [6]。

4.2 局限性

合成样例不能覆盖所有扫描噪声和供应商格式。后续 Acceptance 子集应加入未参与规则调试的公开文档，并由人工标注确认。

5 结论

本文展示了从预检、解析、统一输出到质量门的完整证据链。实验说明，多级标题、表格网格和引用关系需要共同的来源模型，不能由质量层凭空补造。对于无法唯一判断的结构，系统应明确交给人工复核或重新解析。

参考文献

1. Li, M.; Zhang, Y. Document layout analysis for retrieval-augmented generation[J]. Journal of Information Processing, 2024, 32(4): 201-218. DOI:10.1000/jip.2024.03204.
2. 王伟, 陈晨. 面向复杂版面的文档结构恢复 [J]. 中文信息学报, 2023, 37(6): 45-58. DOI:10.1000/cip.2023.3706.
3. Pujara, J.; Singh, H. Evidence graphs for trustworthy document QA[C]. Proceedings of DocEng, 2024: 55-63. DOI:10.1000/doceng.2024.006.
4. Liu, Q.; Chen, R. OCR confidence calibration in enterprise archives[J]. Pattern Recognition Letters, 2022, 158: 12-20. DOI:10.1000/prl.2022.15802.
5. 赵敏, 周海. 表格字段绑定的来源约束与安全降级 [J]. 软件学报, 2025, 36(8): 1771-1787. DOI:10.1000/js.2025.3608.
6. Smith, A.; Patel, R. Human review gates for semantic extraction[C]. Proceedings of ICDAR, 2023: 410-419. DOI:10.1000/icdar.2023.041.

引用规则：正文中的 [1-2] 指向参考文献 1 和 2；[3]、[4]、[5]、[6] 分别指向对应编号。